Arquitetura conceitual da solução

Agente principal, ferramentas, LLM, banco de dados e notícias. Setas representam chamadas; resultados retornam ao solicitante.

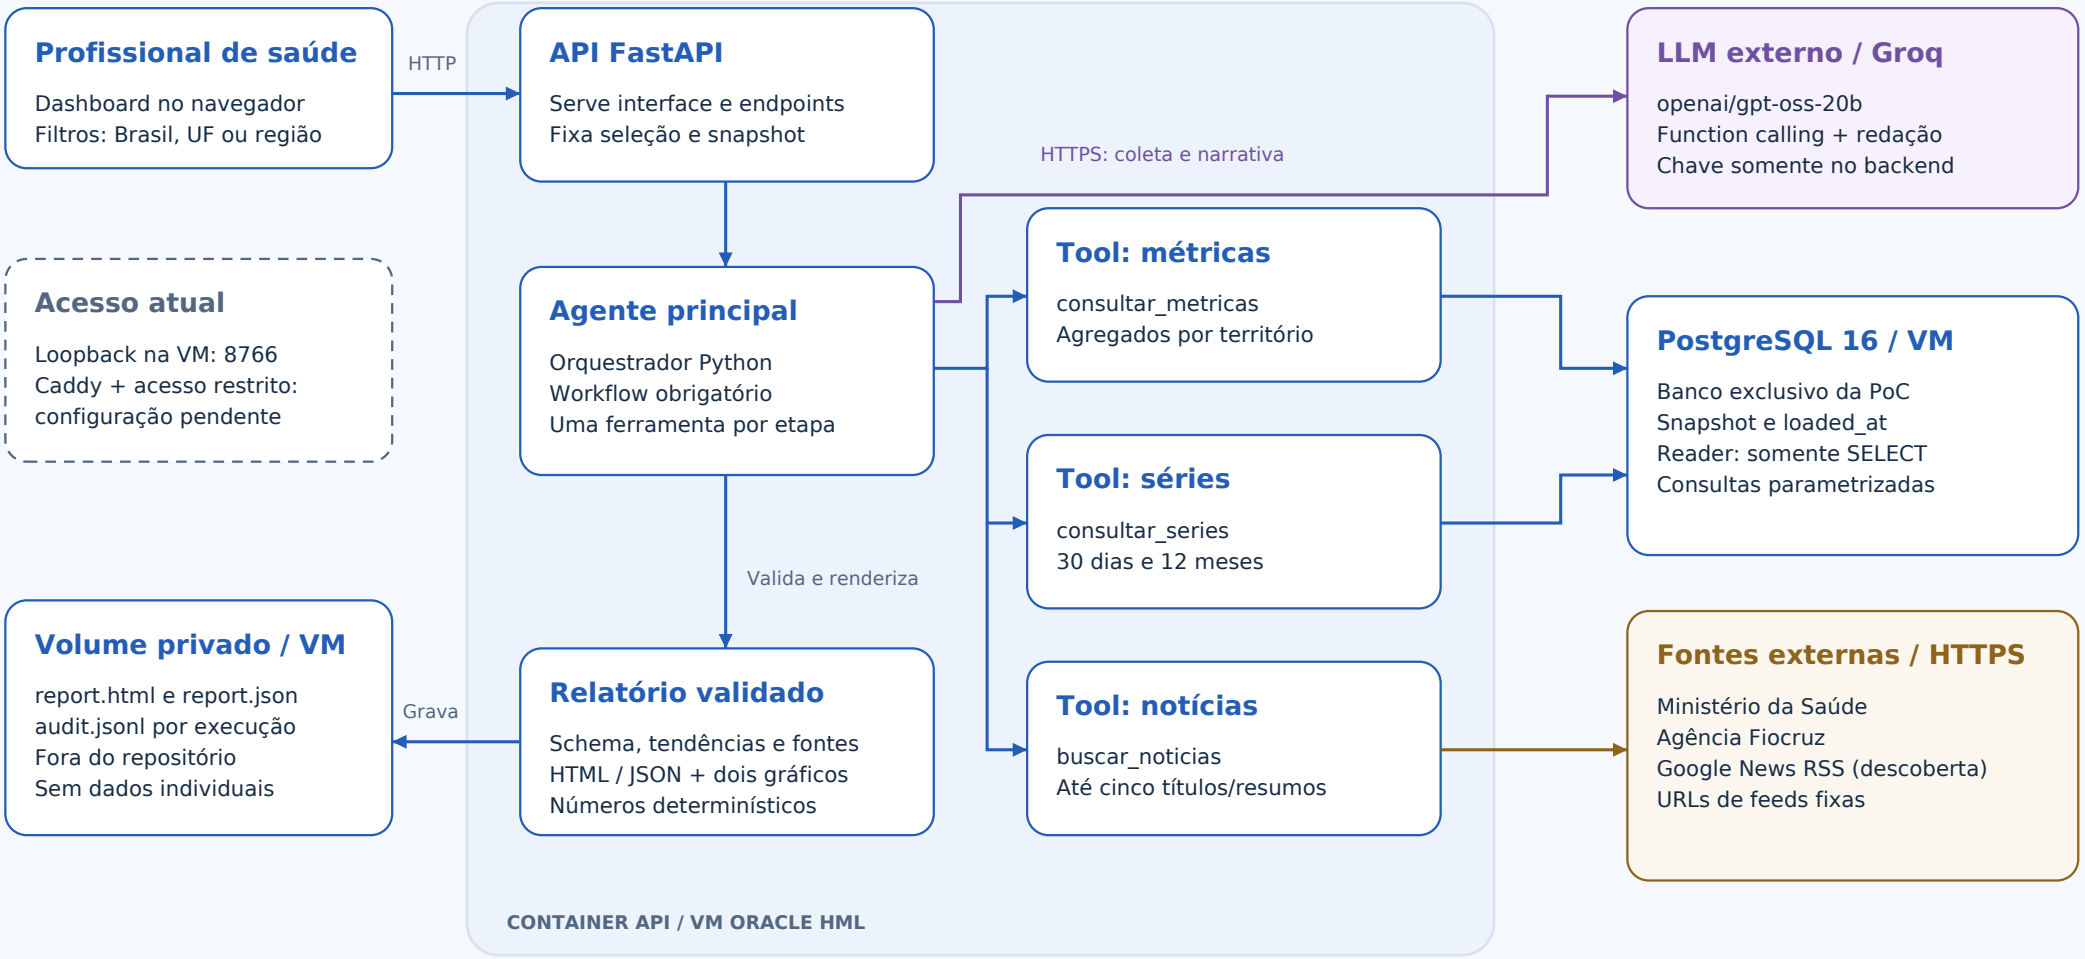

O LLM não executa SQL nem escolhe URLs. Respostas das tools são validadas antes do uso. A redação recebe métricas e notícias; gráficos usam as séries completas do banco.

Azul: serviços e dados da PoC. Roxo: inferência externa. Ocre: notícias externas. Tracejado: exposição externa ainda pendente. O banco e o volume também estão na VM.

Dados, governança e critérios de aceite

A carga histórica e as notícias atuais têm referências temporais distintas. Nenhuma notícia atual explica causalmente os casos de 2019.

1. Fonte histórica

Open DATASUS
CSV de SRAG de 2019
Dicionário e ficha

2. Download auditado

Hash SHA-256 fixado
Arquivo preservado
Sem troca automática de base

3. Agregação Python

Qualidade e categorias
Brasil / UF / região
Supressão de contagens 1 a 4

4. Carga PostgreSQL

Loader exclusivo
Migração e carga idempotente
Snapshot + data da carga

5. Consulta e relatório

Reader sem escrita
Snapshot fixado na geração
Tools + LLM + validação

Auditoria e transparência

Eventos por execução em JSONL.

Ferramenta solicitada, duração, hash do resultado, uso de tokens e decisões de validação.

Modelo, prompt, snapshot, referência histórica, carga e fontes preservados no relatório.

Não registrar chaves, DSNs, raciocínio interno ou rascunhos rejeitados.

Guardrails e operação

Ferramentas fechadas, sem argumentos livres. SQL parametrizado; timeout de leitura.

Três etapas de coleta e uma redação; no máximo um reparo. Validação de texto, tendências e referências.

Uma geração simultânea, intervalo de um minuto e cache completo de cinco minutos.

Quota ou saída inválida: relatório parcial explícito. Um worker e uma réplica.

Escopo e limites dos indicadores

Crescimento de casos e letalidade têm definições e denominadores explícitos.

Internação em UTI entre casos não mede ocupação operacional de leitos.

Vacinação entre casos não mede cobertura populacional nem eficácia.

Notícias: títulos/resumos recentes, sem leitura integral. Proteção contra inferência e acesso externo ainda exigem revisão.

Aceite real de integração / HML em 12/11/2026

Relatório: 62a21130022b4e8296737c20a2de4972. Status complete; três tools; cinco notícias; narrativa validada.
Primeira redação rejeitada por números no comentário atual; reparo único aceito. Dezoito eventos de auditoria.
O teste confere métricas iguais ao dashboard, séries de 30 dias e 12 meses e dois gráficos SVG no HTML.
Evidência informada pelo operador. Não equivale a revisão semântica integral, alta disponibilidade ou liberação pública.
Fontes de arquitetura: código em src/srag/, compose.hml.yml e decisões AI-DLC versionadas no repositório.